Estimadores de Máxima Verosimilitud

21/10/25

Contenidos

1. Introducción
2. Definiciones
3. Bernoulli
4. Poisson
5. Exponencial
6. Normal
7. Uniforme
8. Estimadores insesgados generales

Introducción

- La inferencia estadística consiste en deducir características de una población a partir de una muestra.
- La R.A.E. define *inferir* como: *"Deducir algo o sacarlo como conclusión de otra cosa"*.

Estimador Estadístico

Definición

Un **estimador** es una regla, fórmula o función que nos permite calcular una aproximación de un parámetro poblacional desconocido a partir de los datos de una muestra.

Notación

- θ: Parámetro poblacional desconocido (media, varianza, proporción, etc.)
- $\hat{\theta}$: Estimador del parámetro θ
- $X_1, X_2, \ldots, X_n$: Muestra aleatoria

Forma general

$$\hat{\theta} = g(X_1, X_2, \ldots, X_n)$$

donde g es una función de los datos muestrales.

Estimador insesgado

Definición

Un estimador $\hat{\theta}$ es insesgado si:

$$\mathbb{E}[\hat{\theta}] = \theta$$

Función de verosimilitud

Definición

Dada una muestra $\{x_1, x_2, ..., x_n\}$ de variables aleatorias i.i.d. con función de densidad/probabilidad $f(x;\theta)$, la función de verosimilitud es:

$$L(\theta; x_1, ..., x_n) = \prod_{i=1}^{n} f(x_i;\theta)$$

Función de log-verosimilitud

Definición

Para facilitar los cálculos, se suele trabajar con el logaritmo de la verosimilitud:

$$\ell(\theta; x_1, ..., x_n) = \ln L(\theta; x_1, ..., x_n) = \sum_{i=1}^{n} \ln f(x_i; \theta)$$

Definición

Estimadores de máxima verosimilitud (MLE)

Métodos para estimar los parámetros de una distribución probabilística que maximizan la probabilidad de observar los datos dados.

Situaciones típicas:

- Muestra aleatoria simple: $\{x_1, x_2, ..., x_n\}$
- Variable aleatoria X con función de probabilidad o densidad que depende de parámetros.
- Objetivo: estimar dichos parámetros.

Estimador de máxima verosimilitud (EMV)

Definición

El estimador de máxima verosimilitud $\hat{\theta}_{MV}$ es el valor del parámetro θ que maximiza la función de verosimilitud (o log-verosimilitud):

$$\hat{\theta}_{MV} = \arg\max_{\theta} L(\theta; x_1, ..., x_n)$$

o equivalentemente:

$$\hat{\theta}_{MV} = \arg\max_{\theta} \ell(\theta; x_1, ..., x_n)$$

Método de obtención del EMV

Procedimiento

1. Plantear la función de verosimilitud $L(\theta)$
2. Tomar logaritmo: $\ell(\theta) = \ln L(\theta)$
3. Derivar respecto a θ e igualar a cero:

$$\frac{\partial \ell(\theta)}{\partial \theta} = 0$$

4. Resolver la ecuación para encontrar $\hat{\theta}_{MV}$
5. Verificar que es un máximo (segunda derivada negativa)

Bernoulli - Función de probabilidad y verosimilitud

Función de masa de probabilidad

$$f(x;p) = p^x(1-p)^{1-x}, \quad x = 0, 1$$

Función de verosimilitud

$$L(p; x_1, \ldots, x_n) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}$$

Función de log-verosimilitud

$$\ell(p; x_1, \ldots, x_n) = \left(\sum_{i=1}^{n} x_i\right) \ln p + \left(n - \sum_{i=1}^{n} x_i\right) \ln(1-p)$$

Bernoulli - Estimador de máxima verosimilitud

Obtención del EMV

Derivando la log-verosimilitud:

$$\frac{\partial \ell(p)}{\partial p} = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = 0$$

$$\Rightarrow \frac{\sum x_i}{p} = \frac{n - \sum x_i}{1-p}$$

$$\Rightarrow \hat{p} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

MLE de p

$$\hat{p} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}$$

Poisson - Función de probabilidad y verosimilitud

Función de masa de probabilidad

$$f(k;\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Función de verosimilitud

$$L(\lambda; x_1, \ldots, x_n) = \prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{\prod_{i=1}^{n} x_i!}$$

Función de log-verosimilitud

$$\ell(\lambda; x_1, \ldots, x_n) = \left(\sum_{i=1}^{n} x_i\right) \ln \lambda - n\lambda - \sum_{i=1}^{n} \ln(x_i!)$$

Poisson - Estimador de máxima verosimilitud

Obtención del EMV

Derivando la log-verosimilitud:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = \frac{\sum x_i}{\lambda} - n = 0$$

$$\Rightarrow \hat{\lambda} = \frac{\sum_{i=1}^{n} x_i}{n}$$

MLE de λ

$$\hat{\lambda} = \frac{\sum_{i=1}^{n} x_i}{n} = \bar{x}$$

Exponencial - Función de densidad y verosimilitud

Función de densidad de probabilidad

$$f(x;\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Función de verosimilitud

$$L(\lambda; x_1, \ldots, x_n) = \prod_{i=1}^{n} \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}$$

Función de log-verosimilitud

$$\ell(\lambda; x_1, \ldots, x_n) = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i$$

Exponencial - Estimador de máxima verosimilitud

Obtención del EMV

Derivando la log-verosimilitud:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0$$

$$\Rightarrow \hat{\lambda} = \frac{n}{\sum_{i=1}^{n} x_i} = \frac{1}{\bar{x}}$$

MLE de λ

$$\hat{\lambda} = \frac{1}{\bar{x}}$$

Normal - Función de densidad y verosimilitud

Función de densidad de probabilidad

$$f(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Función de verosimilitud

$$L(\mu,\sigma^2;x_1,\ldots,x_n) = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2}$$

Función de log-verosimilitud

$$\ell(\mu,\sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2$$

Normal - Estimadores de máxima verosimilitud

Obtención del EMV para μ

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^{n} (x_i - \mu) = 0$$

$$\Rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Obtención del EMV para σ^2

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{n} (x_i - \mu)^2 = 0$$

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \hat{\mu})^2$$

Uniforme $U(0, b)$ - Función de densidad y verosimilitud

Función de densidad de probabilidad

$$f(x; b) = \frac{1}{b}, \quad 0 \leq x \leq b$$

Función de verosimilitud

$$L(b; x_1, \ldots, x_n) = \frac{1}{b^n}, \quad \text{para } 0 \leq x_i \leq b$$

Función de log-verosimilitud

$$\ell(b; x_1, \ldots, x_n) = -n \ln b, \quad \text{para } b \geq \text{máx}(x_i)$$

Uniforme $U(0, b)$ - Estimadores

MLE de b

$$\hat{b} = \text{máx}(x_1, x_2, \ldots, x_n)$$

No es insesgado: $\mathbb{E}[\hat{b}] = \frac{n}{n+1} \cdot b$

Versión insesgada

$$\hat{b} = \frac{n+1}{n} \cdot \text{máx}(x_1, x_2, \ldots, x_n)$$

Otro estimador insesgado

$$\hat{b}_2 = 2\bar{X}$$

Pero $\hat{b}$ tiene menor varianza.

Estimador Insesgado de la Media

Para cualquier distribución

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Insesgado: $\mathbb{E}[\hat{\mu}] = \mu$

Estimador Insesgado de la Varianza

Para cualquier distribución

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \hat{\mu})^2$$

Insesgado: $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$

Nota

El factor $\frac{1}{n-1}$ corrige el sesgo al usar $\hat{\mu}$ en lugar de μ.

¡Gracias!