Análisis de la Varianza: ANOVA

Clase del 2/12/2025

Contenidos

1. Introducción
2. Contraste de hipótesis
3. Idea fundamental del ANOVA
4. Fuentes de variación
5. Ejemplo: Puntuaciones en asignaturas
6. Cálculo del ANOVA paso a paso
7. Interpretación de resultados
8. Supuestos del ANOVA
9. Tipos de ANOVA
10. Homogeneidad de varianzas
11. Comparaciones múltiples
12. Ejemplos en IA
13. Conclusiones

Introducción

Análisis de la Varianza (ANOVA)

Es una técnica estadística que permite determinar si existen diferencias significativas entre las medias de dos o más grupos o poblaciones.

Objetivo principal

Evaluar si las variaciones observadas en los datos se deben a:

- Factores específicos (efecto de tratamientos o grupos)
- Variabilidad aleatoria inherente a la muestra

Contraste de hipótesis

Hipótesis nula (H_0)

Todas las medias poblacionales son iguales

$$\mu_1 = \mu_2 = \mu_3 = \dots$$

Hipótesis alternativa (H_1)

Al menos una media poblacional es diferente

Nivel de significación típico: $\alpha = 0{,}05$

Idea fundamental del ANOVA

Variación entre grupos

Diferencias en las medias de los grupos (atribuidas al factor de interés)

Variación dentro de los grupos

Variabilidad natural o aleatoria entre los datos de cada grupo

$$F = \frac{\text{Varianza entre grupos}}{\text{Varianza dentro de los grupos}}$$

Descomposición de la variabilidad

Suma de Cuadrados Total (SST)

$$SST = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2$$

Suma de Cuadrados Entre grupos (SSB)

$$SSB = \sum_{i=1}^{k} n_i (\bar{X}_i - \bar{X})^2$$

Suma de Cuadrados Dentro de grupos (SSW)

$$SSW = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

Relación fundamental: $SST = SSB + SSW$

Definiciones importantes

Símbolos y términos

- X_{ij}: Observación j del grupo i
- $\bar{X}$: Media global
- k: Número de grupos
- n_i: Tamaño del grupo i
- $\bar{X}_i$: Media del grupo i

Interpretación

- **SST**: Variación total
- **SSB**: Variación entre grupos
- **SSW**: Variación dentro de grupos
- **SST = SSB+SSW**

Ejemplo: Comparación de puntuaciones

Contexto del estudio

Se compara las puntuaciones obtenidas por 4 alumnos en 3 asignaturas diferentes (A, B y C) en un test con puntuación máxima de 20.

Alumno	**Asignatura A**	**Asignatura B**	**Asignatura C**
Alumno 1	14	13	19
Alumno 2	12	14	17
Alumno 3	14	10	16
Alumno 4	10	14	19

Cuadro: Puntuaciones obtenidas por los alumnos

Pregunta de investigación

¿Existen diferencias significativas entre las puntuaciones medias de las tres asignaturas?

Hipótesis del ejemplo

Hipótesis nula (H_0)

$$\mu_A = \mu_B = \mu_C$$

Las medias de puntuación de las tres asignaturas son iguales

Hipótesis alternativa (H_1)

Al menos una media de puntuación es diferente

Nivel de significación

$$\alpha = 0{,}05$$

Cálculo paso a paso: Datos iniciales

Datos originales

Alumno	A	B	C
1	14	13	19
2	12	14	17
3	14	10	16
4	10	14	19

Cálculo de medias

$$\bar{X}_A = \frac{14 + 12 + 14 + 10}{4} = 12{,}5$$

$$\bar{X}_B = \frac{13 + 14 + 10 + 14}{4} = 12{,}75$$

$$\bar{X}_C = \frac{19 + 17 + 16 + 19}{4} = 17{,}75$$

$$\bar{X} = \frac{12{,}5 + 12{,}75 + 17{,}75}{3} = 14{,}33$$

Parámetros del estudio

- $k = 3$ grupos (asignaturas)
- $n = 4$ observaciones por grupo
- $N = 12$ observaciones totales

Cálculo de las Sumas de Cuadrados

1. Suma de Cuadrados Entre grupos (SSB)

$$SSB = n\sum_{i=1}^{k}(\bar{X}_i - \bar{X})^2 = 4 \cdot [(12{,}5 - 14{,}33)^2 + (12{,}75 - 14{,}33)^2 + (17{,}75 - 14{,}33)^2]$$

$$SSB = 4 \cdot [(-1{,}83)^2 + (-1{,}58)^2 + (3{,}42)^2] = 4 \cdot [3{,}35 + 2{,}50 + 11{,}70] = 4 \cdot 17{,}55 = 70{,}20$$

2. Suma de Cuadrados Dentro de grupos (SSW)

$$SSW_A = (14 - 12{,}5)^2 + (12 - 12{,}5)^2 + (14 - 12{,}5)^2 + (10 - 12{,}5)^2 = 11{,}00$$

$$SSW_B = (13 - 12{,}75)^2 + (14 - 12{,}75)^2 + (10 - 12{,}75)^2 + (14 - 12{,}75)^2 = 10{,}74$$

$$SSW_C = (19 - 17{,}75)^2 + (17 - 17{,}75)^2 + (16 - 17{,}75)^2 + (19 - 17{,}75)^2 = 6{,}74$$

$$SSW = 11{,}00 + 10{,}74 + 6{,}74 = 28{,}48$$

3. Suma de Cuadrados Total (SST)

$$SST = SSB + SSW = 70{,}20 + 28{,}48 = 98{,}68$$

Cálculo de Grados de Libertad y Cuadrados Medios

Grados de Libertad

$$gl_{\text{entre}} = k - 1 = 3 - 1 = 2$$
$$gl_{\text{dentro}} = N - k = 12 - 3 = 9$$
$$gl_{\text{total}} = N - 1 = 12 - 1 = 11$$

Cuadrados Medios

$$MSB = \frac{SSB}{gl_{\text{entre}}} = \frac{70{,}20}{2} = 35{,}10$$
$$MSW = \frac{SSW}{gl_{\text{dentro}}} = \frac{28{,}48}{9} = 3{,}16$$

Estadístico F

$$F = \frac{MSB}{MSW} = \frac{35{,}10}{3{,}16} = 11{,}09$$

Valor p

Con $F(2, 9) = 11{,}09$:

$$\text{Valor } p = 0{,}0044$$

Comparación con valor crítico

$F_{\text{crítico}}(0{,}05, 2, 9) = 4{,}26$
$11{,}09 > 4{,}26 \Rightarrow$ Rechazar H_0

Tabla ANOVA completa

Fuente de variación	SC	gl	CM	F	Valor p
Entre asignaturas	70.20	2	35.10	11.09	0.0044
Dentro de asignaturas	28.48	9	3.16		
Total	98.68	11			

Cuadro: Tabla ANOVA para el ejemplo de puntuaciones

Interpretación de la tabla

- **SC**: Suma de Cuadrados
- **gl**: Grados de Libertad
- **CM**: Cuadrado Medio (CM = SC/gl)
- **F**: Estadístico F (F = MSB/MSW)

Interpretación de resultados

Resultado del ANOVA

- Estadístico F $= 11.09$
- Valor p $= 0.0044$
- $F_{\text{crítico}}(0{,}05, 2, 9) = 4{,}26$

Regla de decisión

- Si $F_{\text{calculado}} > F_{\text{crítico}}$, rechazar H_0
- Si valor $p < \alpha$, rechazar H_0

Conclusión

Rechazamos H_0
Existen diferencias significativas entre las puntuaciones medias de las tres asignaturas (F=11.09, p=0.0044).

La asignatura C tiene puntuaciones significativamente más altas que A y B.

Supuestos fundamentales

1. Normalidad

Los datos dentro de cada grupo son aproximadamente normales

- ✓ Se puede verificar con pruebas de normalidad

2. Homocedasticidad

Las varianzas son homogéneas entre grupos

- ✓ Pruebas: Levene, Bartlett

3. Independencia

Las observaciones son independientes entre sí

- ✓ Diseño experimental adecuado

Clasificación de ANOVA

ANOVA de un factor

Un solo factor independiente
Ejemplo: Efecto de diferentes fertilizantes sobre crecimiento de plantas

ANOVA de dos factores

Dos factores independientes
Ejemplo: Efecto de fertilizantes **y** tipo de suelo simultáneamente

ANOVA de medidas repetidas

Mismo grupo de sujetos evaluado en **diferentes condiciones**
Ejemplo: Medición del rendimiento antes y después de un tratamiento

Homogeneidad de varianzas

Hipótesis

- $H_0 : \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2$
- H_1: Al menos una varianza es diferente

Prueba de Cochran (para nuestro ejemplo)

Varianzas: $s_A^2 = 3{,}00$, $s_B^2 = 3{,}58$, $s_C^2 = 2{,}25$

$$C = \frac{\text{máx}(S_i^2)}{\sum_{i=1}^{k} S_i^2} = \frac{3{,}58}{3{,}00 + 3{,}58 + 2{,}25} = \frac{3{,}58}{8{,}83} = 0{,}405$$

- Para $k = 3$, $n = 4$, $C_{\textbf{crítico}} \approx 0{,}68$
- Como $0{,}405 < 0{,}68$, no rechazamos H_0

Prueba de Bartlett

Fórmula general de Bartlett

$$\chi^2 = \frac{(N-k)\ln(S_p^2) - \sum_{i=1}^{k}(n_i - 1)\ln(S_i^2)}{1 + \frac{1}{3(k-1)}\left(\sum_{i=1}^{k}\frac{1}{n_i-1} - \frac{1}{N-k}\right)}$$

Para nuestro ejemplo

- $N = 12$ (total de observaciones)
- $k = 3$ (número de grupos)
- $n_i = 4$ (tamaño de cada grupo)
- $S_p^2 = \frac{(n_A-1)s_A^2+(n_B-1)s_B^2+(n_C-1)s_C^2}{N-k} = \frac{3\cdot 3{,}00+3\cdot 3{,}58+3\cdot 2{,}25}{9} = 3{,}16$

Método de Bonferroni

Objetivo

Identificar qué pares específicos de medias difieren significativamente

Hipótesis por par

- $H_0 : \mu_i = \mu_j$
- $H_1 : \mu_i \neq \mu_j$

Criterio de decisión

No se rechaza H_0 si:

$$\frac{|\bar{X}_i - \bar{X}_j|}{\sqrt{\frac{MSE}{n_i} + \frac{MSE}{n_j}}} < t_{n-k, \frac{\alpha}{K}}$$

donde $K = \binom{k}{2}$ (número de comparaciones)

Ejemplo práctico Bonferroni

Datos para nuestro ejemplo

- 3 grupos (A, B, C), $n = 4$ por grupo
- $MSE = 3{,}16$ (de la tabla ANOVA)
- Medias: $\bar{X}_A = 12{,}5$, $\bar{X}_B = 12{,}75$, $\bar{X}_C = 17{,}75$
- $K = 3$, $\alpha_{ajustado} = \frac{0{,}05}{3} \approx 0{,}0167$
- $t_{9,0{,}0167} \approx 2{,}82$

Comparaciones

$$A - B : t = \frac{|12{,}5 - 12{,}75|}{\sqrt{\frac{3{,}16}{4} + \frac{3{,}16}{4}}} = \frac{0{,}25}{\sqrt{1{,}58}} = 0{,}20 < 2{,}82 \quad \text{(No significativo)}$$

$$A - C : t = \frac{|12{,}5 - 17{,}75|}{\sqrt{\frac{3{,}16}{4} + \frac{3{,}16}{4}}} = \frac{5{,}25}{\sqrt{1{,}58}} = 4{,}18 > 2{,}82 \quad \checkmark\textbf{Significativo}$$

$$B - C : t = \frac{|12{,}75 - 17{,}75|}{\sqrt{\frac{3{,}16}{4} + \frac{3{,}16}{4}}} = \frac{5{,}00}{\sqrt{1{,}58}} = 3{,}98 > 2{,}82 \quad \checkmark\textbf{Significativo}$$

Ejemplo 1: Comparación de algoritmos

Objetivo

Evaluar si hay diferencias significativas en precisiones promedio de tres algoritmos:

- SVM
- Random Forest
- KNN

Aplicación

- Aplicados sobre N conjuntos de datos diferentes
- Medir precisión en cada conjunto
- Usar ANOVA para comparar precisiones promedio

Ejemplo 2: Red neuronal - Dos factores

ANOVA de dos factores

Analizar interacción entre:

- **Factor 1**: Tasa de aprendizaje (0.01, 0.1, 0.5)
- **Factor 2**: Número de neuronas (16, 32, 64)

Variable respuesta

Pérdida promedio en validación después de 100 épocas

Ventajas

- Identificar efectos principales de cada factor
- Detectar interacciones entre factores
- Optimizar hiperparámetros sistemáticamente

Ejemplo 3: Preprocesamiento de datos

ANOVA de un factor

Comparar precisión promedio con tres técnicas de preprocesamiento:

- Normalización
- Estandarización
- Imputación de valores faltantes

Diseño experimental

- Aplicar cada técnica a múltiples conjuntos de datos
- Entrenar modelo base (ej: regresión logística)
- Registrar precisión en test
- Usar ANOVA para comparar técnicas

Resultado esperado

Identificar qué técnica produce mejores resultados estadísticamente significativos

Resumen final

Puntos clave del ANOVA

1. **Propósito**: Comparar medias de múltiples grupos
2. **Hipótesis**: H_0: igualdad vs H_1: diferencias
3. **Estadístico**: $F = \frac{MSB}{MSW}$
4. **Supuestos**: Normalidad, homocedasticidad, independencia
5. **Post-hoc**: Comparaciones múltiples (Bonferroni, Tukey)

Aplicaciones prácticas

- Educación: Comparar rendimiento en diferentes asignaturas
- Medicina: Evaluar efectividad de tratamientos
- IA: Comparar algoritmos y técnicas de preprocesamiento
- Investigación: Validar diferencias entre grupos experimentales