Regresión Lineal Simple

Modelado de relaciones entre variables

Clase del 2/12/2025

Contenidos

1. Introducción
2. Componentes del modelo
3. Supuestos del modelo
4. Estimación de parámetros
5. Medidas de bondad de ajuste
6. Inferencia estadística
7. Ejemplo práctico
8. Limitaciones
9. Modelos alternativos
10. Aplicaciones en IA
11. Conclusiones

Introducción

Regresión Lineal Simple

Es una técnica estadística utilizada para modelar la relación entre una variable dependiente (Y) y una variable independiente (X).

Ecuación del modelo

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Aplicaciones

- Predecir ventas en función de gastos en publicidad
- Estimar el peso en función de la altura
- Modelar el rendimiento académico según horas de estudio

Componentes de la Ecuación

Parámetros del modelo

- β_0 (intercepto): Valor esperado de Y cuando $X = 0$
- β_1 (pendiente): Cambio promedio en Y por cada unidad de cambio en X
- ε (error): Diferencia entre valores observados y predichos

Supuesto sobre el error

$$\varepsilon \sim N(0, \sigma^2)$$

Los errores siguen una distribución normal con media 0 y varianza constante

Supuestos del Modelo

1. Linealidad

La relación entre X y Y es lineal

- ✓ Se verifica con diagramas de dispersión

2. Independencia

Las observaciones son independientes entre sí

- ✓ Diseño adecuado del estudio

3. Homocedasticidad

La varianza de los errores (ε) es constante

- ✓ Gráficos de residuos vs valores ajustados

4. Normalidad de errores

Los errores (ε) se distribuyen normalmente

- ✓ Histogramas o tests de normalidad

Estimación por Mínimos Cuadrados

Objetivo

Encontrar $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la suma de cuadrados de los errores:

$$\text{mín} \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2 = \text{mín} \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

Fórmulas de estimación

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n} (X_i - \bar{X})^2} = \frac{Cov(X, Y)}{S_X^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Interpretación

$\hat{\beta}_1$: Por cada unidad que aumenta X, Y aumenta en promedio $\hat{\beta}_1$ unidades

Coeficiente de Correlación (r)

Definición

Mide la fuerza y dirección de la relación lineal entre dos variables:

$$r = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2 \cdot \sum_{i=1}^{n}(Y_i - \bar{Y})^2}} = \frac{Cov(X, Y)}{S_X S_Y}$$

Interpretación de r

- $r > 0$: Relación positiva (cuando X aumenta, Y tiende a aumentar)
- $r < 0$: Relación negativa (cuando X aumenta, Y tiende a disminuir)
- $|r| \approx 1$: Relación lineal fuerte
- $r \approx 0$: No hay relación lineal significativa

Coeficiente de Determinación (R^2)

Definición

Proporción de la variabilidad de Y explicada por el modelo:

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}$$

Interpretación

- $0 \leq R^2 \leq 1$
- $R^2 = 1$: Modelo perfecto
- $R^2 = 0$: Modelo no explica nada

Componentes

- SST: Variación total
- SSE: Variación no explicada
- SSR: Variación explicada

$$SST = SSE + SSR$$

Pruebas de hipótesis para los coeficientes

Para la pendiente β_1

- $H_0 : \beta_1 = 0$ (no hay relación lineal)
- $H_1 : \beta_1 \neq 0$ (hay relación lineal)

Estadístico de prueba

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t_{n-2}$$

donde $SE(\hat{\beta}_1) = \sqrt{\frac{MSE}{\sum(X_i - \bar{X})^2}}$

Regla de decisión

Rechazar H_0 si $|t| > t_{\alpha/2,n-2}$ o si valor p ¡ α

Intervalos de confianza

Para la pendiente β_1

$$\hat{\beta}_1 \pm t_{\alpha/2,n-2} \cdot SE(\hat{\beta}_1)$$

Para el intercepto β_0

$$\hat{\beta}_0 \pm t_{\alpha/2,n-2} \cdot SE(\hat{\beta}_0)$$

Nivel de confianza típico

$\alpha = 0{,}05$ (95 % de confianza)

Interpretación

Con 95 % de confianza, el verdadero valor del parámetro está dentro del intervalo

Ejemplo: Datos de práctica

Conjunto de datos

Relación entre una variable X y una variable Y

x	y
1.91944566	7.12549343
-2.060077085	-5.180342531
0.337049702	1.999447729
-1.228049614	-2.744132982
3.961169443	13.1254884
0.331224664	2.167026598
-2.889559568	-7.731191896
1.946934589	6.262488294
1.009315806	4.151638995

Cuadro: Datos para el ejemplo de regresión

Cálculo de estadísticos básicos

Cálculos intermedios

X_i	Y_i	$X_i Y_i$	X_i^2
1.9194	7.1255	13.6770	3.6843
-2.0601	-5.1803	10.6719	4.2439
0.3370	1.9994	0.6739	0.1136
-1.2280	-2.7441	3.3699	1.5081
3.9612	13.1255	51.9923	15.6909
0.3312	2.1670	0.7178	0.1097
-2.8896	-7.7312	22.3397	8.3496
1.9469	6.2625	12.1927	3.7906
1.0093	4.1516	4.1903	1.0187
$\Sigma X = 3{,}3275$	$\Sigma Y = 19{,}1760$	$\Sigma XY = 119{,}8255$	$\Sigma X^2 = 38{,}5093$

Cálculo de estadísticos básicos

Medias

$$\bar{X} = \frac{\Sigma X}{n} = 0{,}3697$$
$$\bar{Y} = \frac{\Sigma Y}{n} = 2{,}1307$$

Sumas de cuadrados

$$S_{XX} = \sum (X_i - \bar{X})^2 = \Sigma X_i^2 - n\bar{X}^2 = 37{,}2790$$
$$S_{YY} = \sum (Y_i - \bar{Y})^2 = \Sigma Y_i^2 - n\bar{Y}^2$$
$$S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y}) = \Sigma X_i Y_i - n \cdot \bar{X} \cdot \bar{Y} = 112{,}7362$$

Estimación de parámetros

Cálculo de $\hat{\beta}_1$

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}$$

Cálculo de $\hat{\beta}_0$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Resultados del ejemplo

$\hat{\beta}_1 = 3{,}024$ $\qquad$ $\hat{\beta}_0 = 1{,}0127$

Ecuación: $\hat{Y} = 1{,}0127 + 3{,}024X$

Interpretación

Por cada unidad que aumenta X, Y aumenta en promedio 3.024 unidades

Medidas de bondad de ajuste

Coeficiente de correlación

$$r = \frac{S_{XY}}{\sqrt{S_{XX} \cdot S_{YY}}} = 0{,}999$$

- Relación lineal fuerte y positiva

Coeficiente de determinación

$$R^2 = r^2 = (0{,}999)^2 = 0{,}998$$

- 99.8 % de la variabilidad de Y es explicada por el modelo

Interpretación general

El modelo lineal explica muy bien la relación entre X e Y

Diagrama de dispersión y línea de regresión

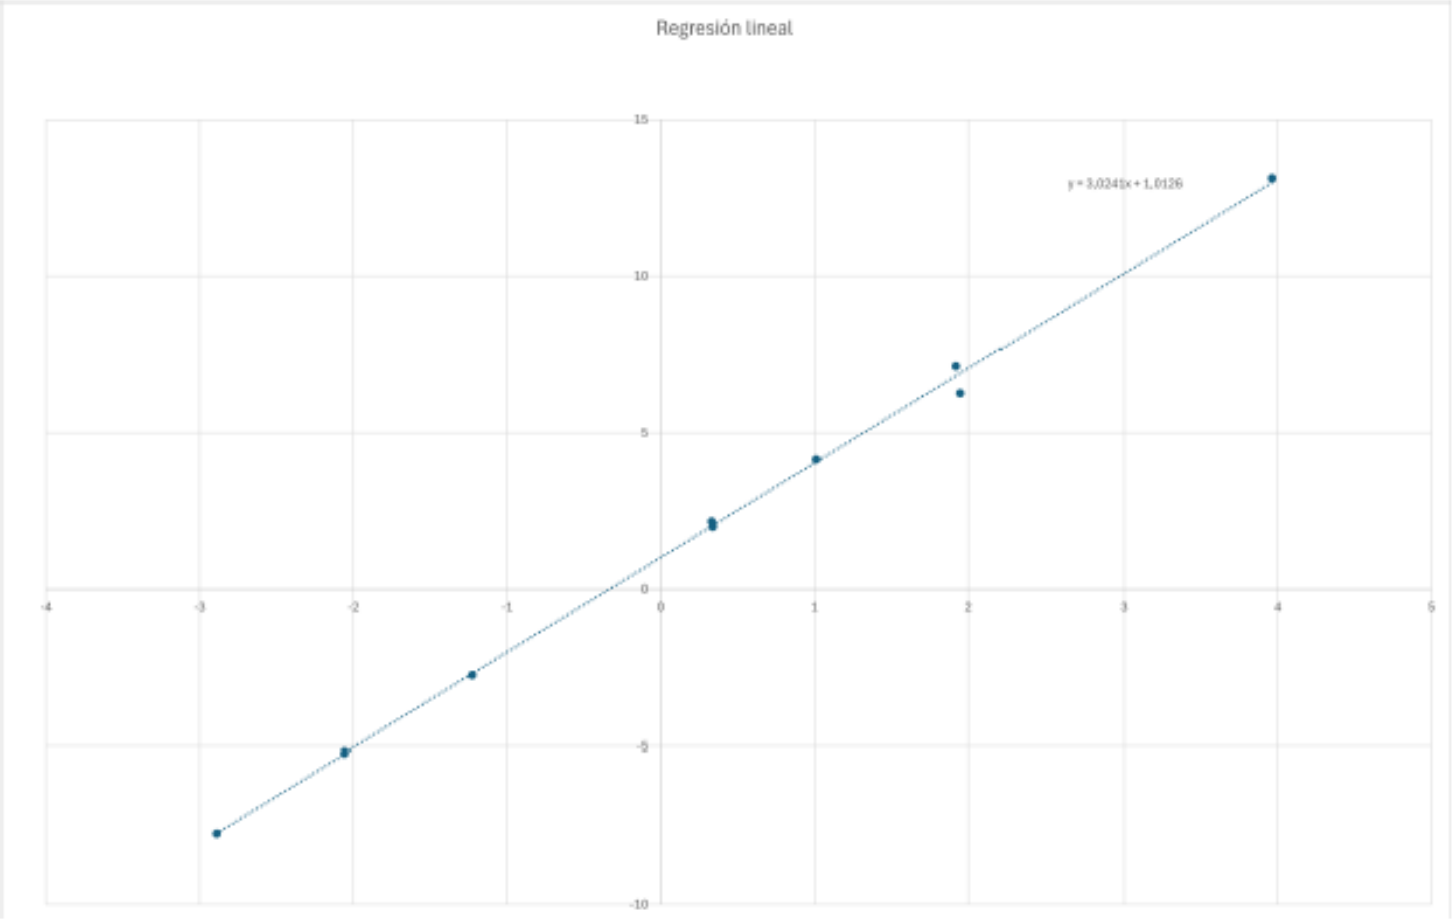

Figura: Diagrama de dispersión con línea de regresión lineal

Inferencia sobre los parámetros

Prueba para β_1

- $H_0 : \beta_1 = 0$
- $H_1 : \beta_1 \neq 0$
- $t = 16{,}24$, valor p $< 0{,}001$
- Rechazar H_0: La pendiente es significativamente diferente de cero

Intervalos de confianza (95 %)

- Para β_1: [2.78, 3.72]
- Para β_0: [-0.12, 1.98]

Conclusión

Existe una relación lineal significativa entre X e Y
Por cada unidad de X, Y aumenta entre 2.78 y 3.72 unidades (con 95 % de confianza)

Limitaciones de la Regresión Lineal Simple

1. Sensibilidad a valores atípicos

- ✗ Valores extremos pueden distorsionar los coeficientes
- ✓ Solución: Identificar y tratar outliers

2. Solo captura relaciones lineales

- ✗ No adecuado para relaciones no lineales
- ✓ Solución: Transformaciones o modelos no lineales

3. Supuesto de independencia

- ✗ Puede violarse en datos temporales o espaciales
- ✓ Solución: Verificar con tests de autocorrelación

4. Una sola variable independiente

- ✗ Ignora otros factores que podrían influir
- ✓ Solución: Regresión múltiple

Modelos de regresión alternativos

Cuando la relación no es lineal

- **Regresión polinómica:** $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_k X^k$
- **Regresión exponencial:** $Y = \alpha e^{\beta X}$
- **Regresión logarítmica:** $Y = \beta_0 + \beta_1 \ln(X)$
- **Regresión potencial:** $Y = \alpha X^{\beta}$

Transformaciones comunes

- Para linealizar: $\ln(Y)$, $\sqrt{Y}$, $1/Y$
- Cambio de variable: $X' = X^2$, $X' = \ln(X)$

Selección del modelo

- Basarse en diagramas de dispersión
- Comparar R^2 ajustado
- Validar supuestos de los residuos

Aplicaciones en Inteligencia Artificial

1. Predicción de precios

- Predecir precio de viviendas en función de metros cuadrados
- Estimar costos de producción según cantidad producida

2. Análisis de tendencias

- Modelar crecimiento de usuarios en redes sociales
- Predecir ventas estacionales

3. Como componente de modelos complejos

- Capa final en redes neuronales para regresión
- Base para algoritmos más sofisticados (LASSO, Ridge)

Limitaciones en IA moderna

- Muy simple para problemas complejos
- No captura interacciones entre múltiples variables
- Supuestos restrictivos para datos reales

Resumen final

Puntos clave de la Regresión Lineal Simple

1. **Propósito**: Modelar relaciones lineales entre dos variables
2. **Modelo**: $Y = \beta_0 + \beta_1 X + \varepsilon$
3. **Estimación**: Mínimos cuadrados ordinarios
4. **Bondad de ajuste**: r y R^2
5. **Inferencia**: Tests e intervalos para β_0 y β_1
6. **Supuestos**: Linealidad, independencia, homocedasticidad, normalidad

Áreas de aplicación

- Economía y finanzas
- Ciencias sociales
- Ingeniería
- Medicina
- Machine Learning (como base)